به نام خدا

دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
تمرین امتیازی شماره 1

نام و نام خانوادگی	**محمد پویا افشاری – علیرضا اسمعیل زاده**
شماره دانشجویی	**810198351-810198577**
تاریخ ارسال گزارش	**1402.09.17**

فهرست

شکل‌ها

پاسخ ۱ –

۱-۱ توضیحات مدل

مدل مورد بررسی یک شبکه عصبی کانولوشنال بازگشتی دو جهته (BRCNN) است که برای طبقه‌بندی رابطه بر اساس کوتاه‌ترین مسیر وابستگی (SDP) بین موجودیت‌های یک جمله طراحی شده است. این معماری شامل شبکه‌های عصبی بازگشتی دو کاناله است که مجهز به واحدهای حافظه کوتاه‌مدت (LSTM)، لایه‌های کانولوشن و لایه‌های تجمع حداکثری هستند.

ورودی مدل از یک جمله و درخت وابستگی متناظر آن، با تمرکز بر کوتاهترین مسیر وابستگی (SDP) مشتق شده است. دو کانال مجزا به کار گرفته شده است، یکی به کلمات و دیگری به روابط وابستگی اختصاص داده شده است.
واحدهای LSTM نقشی محوری در نمایش کلمات و روابط وابستگی دارند. هر کلمه و رابطه وابستگی با استفاده از جداول جاسازی شده در یک بردار با ارزش واقعی کدگذاری می شود.
در طول آموزش، مدل هم SDP و هم معکوس آن را در نظر می گیرد. طبقه‌بندی‌کننده‌های softmax ریزدانه، طبقه‌بندی کلاس (K + 12) را برای هر جهت تسهیل می‌کنند. خروجی های دو RCNN به هم متصل شده و به یک طبقه بندی کننده softmax دانه درشت برای طبقه بندی کلاس (K + 1) تغذیه می شوند.
SDP که برای گرفتن روابط موجودیت حیاتی است، بر اساس موقعیت موجودیت ها در درخت وابستگی تعیین می شود.
واحدهای LSTM برای مدل‌سازی داده‌های متوالی استفاده می‌شوند که در مدیریت وابستگی‌های بلندمدت مهارت دارند. مکانیسم‌های دروازه‌ای تطبیقی، از جمله دروازه ورودی، دروازه فراموشی، دروازه خروجی و سلول حافظه، به اثربخشی مدل کمک می‌کنند.

لایه‌های کانولوشن ویژگی‌های محلی را از بازنمایی‌های پنهان کلمات همسایه و روابط وابستگی متناظر آن‌ها می‌گیرند.

max pooling layer اطلاعات را از ویژگی های محلی استخراج شده از SDP یا معکوس آن جمع می کند. لایه‌های Softmax برای طبقه‌بندی استفاده می‌شوند و توزیع‌های احتمال را برای کلاس‌های مختلف ارائه می‌کنند.

در طول مرحله آموزش، دو طبقه‌بندی‌کننده softmax ریز دانه، طبقه‌بندی کلاس (K + 12) را برای هر جهت انجام می‌دهند. لایه های ادغام دو RCNN به هم پیوسته اند و یک لایه خروجی softmax دانه درشت برای طبقه بندی کلاس (K + 1) استفاده می شود.

این مدل برای وظایف طبقه‌بندی رابطه، با تأکید خاص بر گرفتن اطلاعات دوطرفه در امتداد SDP در درخت وابستگی یک جمله، طراحی شده است. برای هرگونه سوال یا توضیح خاص، در بحث بیشتر شرکت کنید.

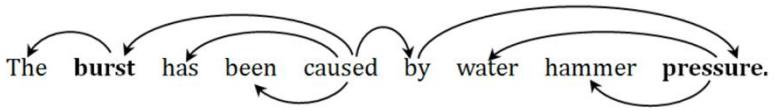

Realtion	Shortest Dependency Path
Cause-Effect(e_2,e_1)	burst ←nsubjpass— caused —prep→ by —pobj→ pressure
Cause-Effect(e_1,e_2)	pressure ←pobj— by ←prep— caused —nsubjpass→ burst

نمایش مثالی از کوتاهترین مسیر وابستگی برای یک جمله

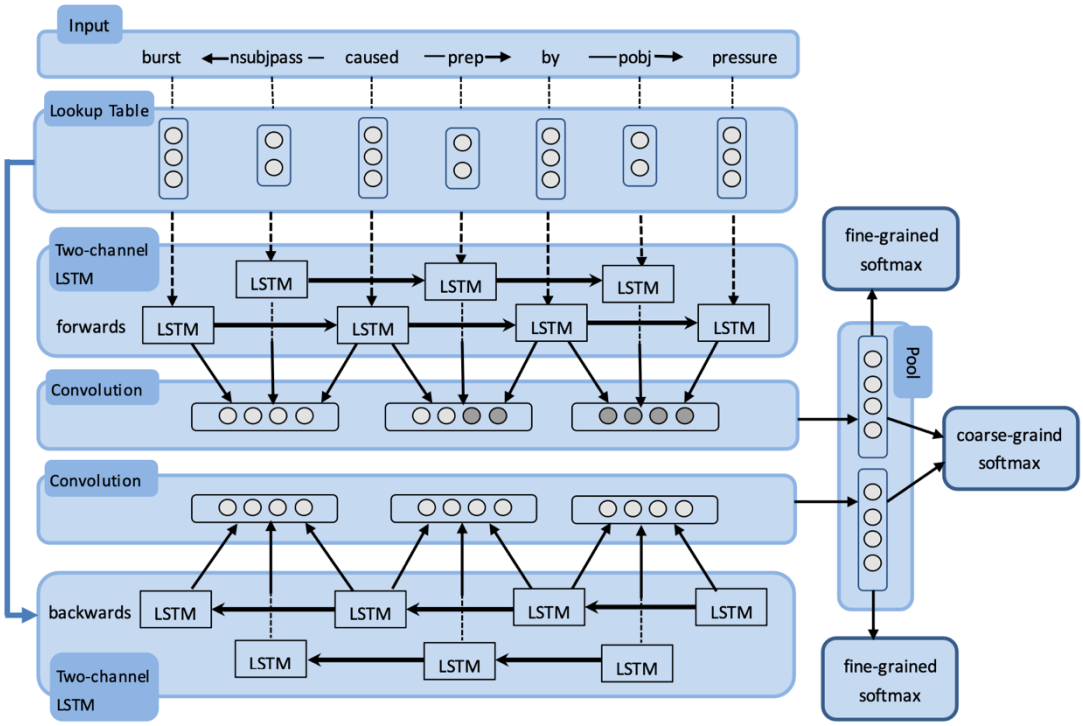

معماری مدل

۱-۲ توضیحات مجموعه دادگان و پیش پردازش آنها

۱-۱-۲. گرفتن دادگان

```
from google.colab import drive
drive.mount('/content/drive')
```

اتصال به گوگل کلود برای استفاده از داده های آپلود شده بر روی کلود

```
with
open("/content/drive/MyDrive/SemEval2010_task8_all_data/SemEval2010_task8_training/TRAIN_FILE.TXT")
as f:
    train_file = f.readlines()
```

```
with
open("/content/drive/MyDrive/SemEval2010_task8_all_data/SemEval2010_task8_testing_keys/TEST_FILE_FULL.TXT") as f:
    test_file = f.readlines()
```

در فایل TRAIN_FILE.TXT دادگان آموزش قرار دارد و که تعداد جملات آن ۸۰۰۰ است و تعداد جملات داده های تست ۲۷۱۷ است که در فایل TEST_FILE_FULL.TXT قرار دارند با استفاده از فایل Bidirectional_Dataset.ipynb که در صورت تمرین قرار داده شده بود این فایل ها را که در کلود قرار گرفته اند را می خوانیم.

```
def prepare_dataset(raw):
    sentences, relations = [], []
    to_replace = [("\"", ""), ("\n", ""), ("<", " <"), (">", "> ")]
    last_was_sentence = False
    for line in raw:
        sl = line.split("\t")
        if last_was_sentence:
            relations.append(sl[0].split("(")[0].replace("\n", ""))
            last_was_sentence = False
        if sl[0].isdigit():
            sent = sl[1]
            for rp in to_replace:
                sent = sent.replace(rp[0], rp[1])
            sentences.append(sent)
            last_was_sentence = True
    print("Found {} sentences".format(len(sentences)))
    return sentences, relations


def Labeler(relations):
    Label=[]
    for i in relations:
        if i=='Entity-Destination':
            Label.append(0)
        if i=='Entity-Origin':
            Label.append(1)
        if i=='Component-Whole':
            Label.append(2)
        if i=='Member-Collection':
            Label.append(3)
        if i=='Other':
            Label.append(4)
        if i=='Message-Topic':
            Label.append(5)
        if i=='Content-Container':
            Label.append(6)
        if i=='Instrument-Agency':
            Label.append(7)
        if i=='Product-Producer':
            Label.append(8)
```

```
        if i=='Cause-Effect':
            Label.append(9)
    return Label
```

تابعی که در فایل Bidirectional_Dataset.ipynb برای آماده سازی داده ها است را به پروژه اضافه می کنیم.

```
train_sentences, train_relations = prepare_dataset(train_file)
test_sentences, test_relations = prepare_dataset(test_file)

train_label = Labeler(train_relations)
test_label = Labeler(test_relations)
```

```
Found 8000 sentences
Found 2717 sentences
```

با استفاده از این دو تابع Labler و prepare_dataset فایل های آموزش و تست را به آرایه از جملات و روابط آن ها تبدیل می کنیم و سپس با استفاده از تابع Labler این روابط را به اعداد ۰ تا ۹ نگاشت می دهیم. تعداد جملات خوانده شده هم مانند مقاله ۸۰۰۰ و ۲۷۱۷ است.

۲-۱-۲. ترسیم نمودار های دادگان

```
import matplotlib.pyplot as plt

# Plotting the distribution of sentence lengths
plt.figure(figsize=(10, 6))

plt.bar(['Train Sentences', 'Test Sentences'], [len(train_sentences), len(test_sentences)], color=['blue', 'green'])

plt.title('Data')
plt.xlabel('Sentence Length')
plt.ylabel('Frequency')

plt.show()
```

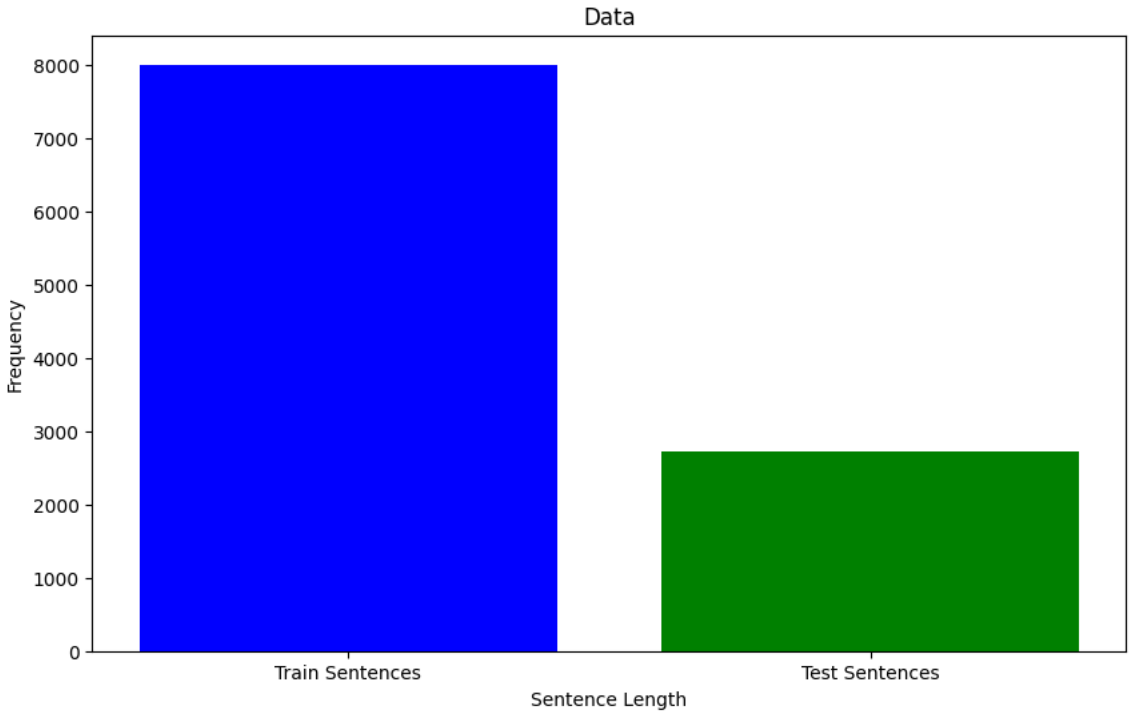

تعداد جملات تست و آموزش

تعداد جملات تست و آموزش را که در کد قبلی نمایش دادیم را در اینجا ترسیم می کنیم.

```
import matplotlib.pyplot as plt
from collections import Counter

# Count occurrences of each integer in train_label and test_label
train_counts = Counter(train_label)
test_counts = Counter(test_label)

# Get unique integers and their counts
train_values, train_counts = zip(*train_counts.items())
test_values, test_counts = zip(*test_counts.items())

# Create bar plots for train_label and test_label
plt.bar(train_values, train_counts, color='blue', label='Train')
plt.bar(test_values, test_counts, color='green', label='Test', alpha=0.7)  # Use alpha to make bars semi-transparent

# Set labels and title
plt.xlabel('class')
plt.ylabel('Count')
plt.title('Count of class in Train and Test')

# Add legend
plt.legend()


# Show the plot
plt.show()
```

تعداد کلاس ها در داده های آموزش و تست

در اینجا تعداد کلاس ها در داده های آموزش و تست را نمایش می دهیم برای شمارش کلاس ها از تابع Counter استفاده میکنیم. بیشتر کلاس ها از نوع other (سایر) و کمترین تعداد نیز برای کلاس Instrument Agency است.

```
all_label = train_label + test_label

counts = Counter(all_label)

# Get unique integers and their counts
label_values, label_counts = zip(*counts.items())


# Create bar plots for all_label
plt.bar(label_values, label_counts, color='blue', label='Data')

# Set labels and title
plt.xlabel('class')
plt.ylabel('Count')
plt.title('Count of each class')

# Add legend
plt.legend()

# Show the plot
plt.show()
```

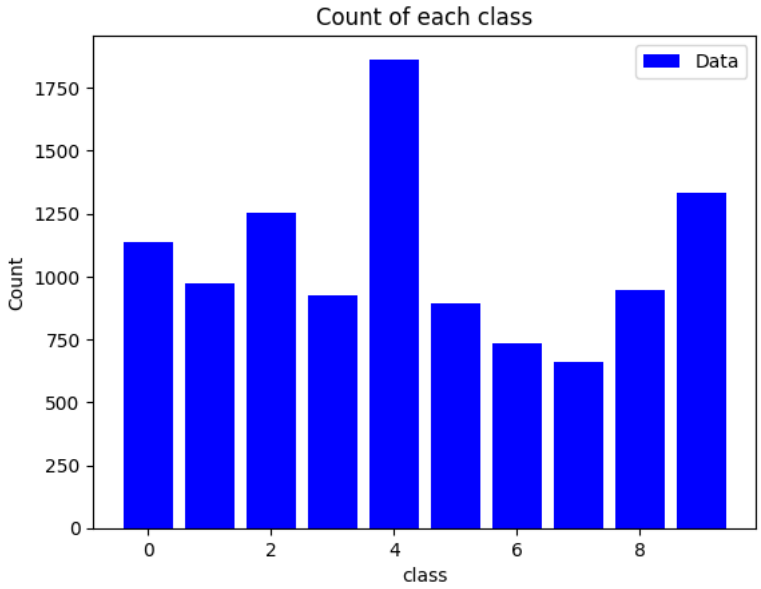

تعداد نمونه در هر کلاس در کل دادگان

تعداد نمونه در هر کلاس را در کل داده ها در نظر میگیریم که با مشابه قسمت قبل با تفاوت تجمیع داده ها

```
print(test_sentences[0])
```

```
The most common  <e1> audits </e1>  were about  <e2> waste </e2>  and recycling.
```

نمایش جمله نمونه از داده های تست

۳-۱-۲. پیش پردازش دادگان

```
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences

# Create a tokenizer
tokenizer = Tokenizer()

# Fit the tokenizer on the training sentences
tokenizer.fit_on_texts(train_sentences)

# Fit the tokenizer on the testing sentences
tokenizer.fit_on_texts(test_sentences)


# Convert training and test sentences to sequences of tokens
train_sequences = tokenizer.texts_to_sequences(train_sentences)
test_sequences = tokenizer.texts_to_sequences(test_sentences)

# Get the word index mapping
word_index = tokenizer.word_index

# Pad sequences to the same length
max_length = max(max(len(seq) for seq in train_sequences), max(len(seq) for seq in test_sequences))
```

```
padded_train_sequences = pad_sequences(train_sequences, maxlen=max_length, padding='post')
padded_test_sequences = pad_sequences(test_sequences, maxlen=max_length, padding='post')

# Print the results
print("Word Index:")
print(word_index)

print("Word Index Size:")
print(len(word_index))

print("\nTraining Sequences:")
print(train_sequences)

print("\nPadded Training Sequences:")
print(padded_train_sequences)

print("\nTest Sequences:")
print(test_sequences)

print("\nPadded Test Sequences:")
print(padded_test_sequences)

print()
```

```
Word Index:
 {'e1': 1, 'e2': 2, 'the': 3, 'of': 4, 'a': 5, 'and': 6, 'in': 7, 'to': 8, 'is': 9, 'was': 10, 'from': 11, 'by': 12, 'with': 13, 'on': 14,
                                                                                                                    'that': 15, 'into': 16, …}
Word Index Size:
22900

Training Sequences:
[[3, 101, 19, 515, 419, 22, 47, 1000, 1491, 7, 18, 7631, 1, 4146, 1, 4, 2270, 2, 2271, 2], [3, 1, 436, 1, 10, 1492,
2491, 6, 3117, 16, 3, 2, 2492, 2, 12, 853, 4, 5, 1908], …], …]

Padded Training Sequences:
[[   3  101   19 ...    0    0    0]
 [   3    1  436 ...    0    0    0]
 [   3    1  240 ...    0    0    0]
 ...
 [   8  790   20 ...    0    0    0]
 [   3 1436    6 ...    0    0    0]
 [   3    1 1948 ...    0    0    0]]

Test Sequences:
[[3, 68, 260, 1, 19827, 1, 31, 53, 2, 1568, 2, 6, 7353], [3, 1, 87, 1, 9997, 236, 2, 3900, 2], [3, 250, 1, 1757, 1,
3695, 3, 10666, 13, 5, 2, 827, 2], …]

Padded Test Sequences:
[[    3    68   260 ...     0     0     0]
 [    3     1    87 ...     0     0     0]
 [    3   250     1 ...     0     0     0]
 ...
 [    3     1  1939 ...     0     0     0]
 [22897     3   488 ...     0     0     0]
 [    5   161   307 ...     0     0     0]]
```

با استفاده از کتابخانه Tokenizer بر روی جملات آموزش و تست با کمک تابع fit_on_texts شاخص منحصر به فرد برای هر داده ایجاد می کنیم که تعداد آن برابر Word Index و برابر ۲۲۹۰۰ کلمه است سپس با استفاده از تابع texts_to_sequences جملات آموزش و تست را به دنباله ای از شاخص ها تبدیل می کنیم که به هر کلمه

یک عدد منحصر به فرد نسبت می دهد به دلیل آنکه طول جملات یکسان نیست نیاز است تا بر روی دنباله ایجاد شده با استفاده از تابع pad_sequences طول دنباله ها را به ۸۹ میرسانیم که طولانی ترین جمله در داده های آموزش و تست است.

```
# Count lengths of padded sequences
train_lengths = Counter(len(seq) for seq in padded_train_sequences)
test_lengths = Counter(len(seq) for seq in padded_test_sequences)

print("Count of Lengths in Training Sequences:")
print(train_lengths)

print("Count of Lengths in Test Sequences:")
print(test_lengths)
```

```
Count of Lengths in Training Sequences:
Counter({89: 8000})
Count of Lengths in Test Sequences:
Counter({89: 2717})
```

برای اطمینان از عملکرد تابع pad_sequences طول دنباله ها را شمارش می کنیم و مشخص است همه آن ها برابر ۸۹ هستند.

```
num_classes = max(max(train_label), max(test_label)) + 1
print(num_classes)
```

```
10
```

تعداد کلاس ها برابر ۱۰ است چون در تابع Labler ما خروجی ۰ تا ۹ داشتیم ولی قبل از کد گذاری یک طرفه از تعداد آن اطمینان کسب می کنیم.

```
from tensorflow.keras.utils import to_categorical

# Convert train and test labels to one-hot encoding
class_number = 10
one_hot_train_labels = to_categorical(train_label, num_classes=class_number)
one_hot_test_labels = to_categorical(test_label, num_classes=class_number)

# Print the results
print("Original Train Labels:")
print(train_label)

print("\nOne-Hot Encoded Train Labels:")
print(one_hot_train_labels)

print("\nOriginal Test Labels:")
print(test_label)

print("\nOne-Hot Encoded Test Labels:")
print(one_hot_test_labels)
```

```
Original Train Labels:
[2, 4, 7, 4, 3, 4, 9, 0, 6, 0, 3, 4, 5, 9, 7, 5, 7, 8, 2, 3, 1, 3, 9, 4, 3, 4, 9, 5, 5, 2, 5, 9, 8, 0, 2, 1, 4, 2, 9, 7, 9, 6, 3,
1, 9, 7, 7, 9, 4, 4, 9, 2, 9, 9,...]
One-Hot Encoded Train Labels:
```

```
[[0. 0. 1. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 1. 0. 0.]
 ...
 [1. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 1. 0.]]

Original Test Labels:
[5, 8, 7, 0, 9, 2, 8, 3, 2, 5, 0, 4, 0, 8, 1, 1, 0, 4, 3, 8, 5, 6, 8, 4, 1, 8, 9, 4, 4, 1, 9, 5, 2, 8, 2, 2, 3, 6, 3, 8, 9, 2, 9,
0, 1, 6, 4, 0, 5, 4, 0, 4, 3, 4, 9,...]

One-Hot Encoded Test Labels:
[[0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 1. 0.]
 [0. 0. 0. ... 1. 0. 0.]
 ...
 [0. 0. 1. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 1. 0.]
 [1. 0. 0. ... 0. 0. 0.]]
```

با استفاده از تابع to_categorical کد گذاری یک طرفه یا همان one hot را انجام می دهیم و همان طور که در خروجی مشخص است کد گذاری درست انجام شده است.

۲-۳ ساخت مدل

```python
from keras.models import Sequential
from keras.layers import Embedding, Bidirectional, LSTM, Conv1D, MaxPooling1D, Flatten, Dense

# Model Definition
model = Sequential()

# Embedding Layer
model.add(Embedding(input_dim=(len(word_index)+1), output_dim=50, input_length=max_length))

# Bidirectional LSTM
model.add(Bidirectional(LSTM(50, return_sequences=True)))

# Convolutional Layers
model.add(Conv1D(200, kernel_size=3, activation='relu'))
model.add(MaxPooling1D(pool_size=2))

model.add(Flatten())

# Output Layer
# Assuming you have n_classes for the number of relation classes
model.add(Dense(class_number, activation='softmax'))

# Compile the model
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

# Print the model summary
model.summary()
```

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
```

```
=================================================================
 embedding (Embedding)       (None, 89, 50)            1145050

 bidirectional (Bidirection  (None, 89, 100)           40400
 al)

 conv1d (Conv1D)             (None, 87, 200)           60200

 max_pooling1d (MaxPooling1  (None, 43, 200)           0
 D)

 flatten (Flatten)           (None, 8600)              0

 dense (Dense)               (None, 10)                86010

=================================================================
Total params: 1331660 (5.08 MB)
Trainable params: 1331660 (5.08 MB)
Non-trainable params: 0 (0.00 Byte)
```

طبق مقاله در قسمت Hyperparameter Settings مقدار embedding برابر 50-dimensional هستند و به صورت تصادفی مقداردهی اولیه می شوند. لایه های مخفی در هر کانال به اندازه تعداد embedding (200 یا 50) بودند. لایه convolution 200 بعدی بود. به دلیل برابر بودن ابعاد لایه های مخفی و embedding مقدار ۵۰ برای آن انتخاب شده است. شبکه دارای یک Bidirectional LSTM است که خروجی آن به یک لایه convolution سپس به یک MaxPooling متصل میشود و در نهایت به یک لایه Dense اضافه میکنیم تا خروجی برابر تعداد کلاس ها یا همان ۱۰ بدهد.

```
train_history = model.fit(padded_train_sequences, one_hot_train_labels, epochs=20, batch_size=32,
validation_split=0.1)
```

```
Epoch 1/20
225/225 [==============================] - 34s 150ms/step - loss: 0.2611 - accuracy: 0.9369 -
val_loss: 1.2720 - val_accuracy: 0.6706
Epoch 2/20
225/225 [==============================] - 33s 146ms/step - loss: 0.0335 - accuracy: 0.9908 -
val_loss: 1.7789 - val_accuracy: 0.6956
Epoch 3/20
225/225 [==============================] - 32s 142ms/step - loss: 0.0034 - accuracy: 0.9996 -
val_loss: 2.2718 - val_accuracy: 0.6950
Epoch 4/20
225/225 [==============================] - 33s 146ms/step - loss: 0.0060 - accuracy: 0.9996 -
val_loss: 2.0003 - val_accuracy: 0.6919
Epoch 5/20
225/225 [==============================] - 31s 136ms/step - loss: 0.0022 - accuracy: 0.9996 -
val_loss: 2.0879 - val_accuracy: 0.6888
Epoch 6/20
225/225 [==============================] - 31s 137ms/step - loss: 3.2250e-04 - accuracy: 1.0000 -
val_loss: 2.2725 - val_accuracy: 0.6894
Epoch 7/20
225/225 [==============================] - 30s 132ms/step - loss: 1.7616e-04 - accuracy: 1.0000 -
val_loss: 2.3090 - val_accuracy: 0.6919
Epoch 8/20
225/225 [==============================] - 30s 133ms/step - loss: 1.0509e-04 - accuracy: 1.0000 -
val_loss: 2.4220 - val_accuracy: 0.6919
Epoch 9/20
225/225 [==============================] - 31s 136ms/step - loss: 5.7961e-05 - accuracy: 1.0000 -
val_loss: 2.4882 - val_accuracy: 0.6919
Epoch 10/20
225/225 [==============================] - 32s 140ms/step - loss: 4.2573e-05 - accuracy: 1.0000 -
val_loss: 2.5516 - val_accuracy: 0.6950
Epoch 11/20
225/225 [==============================] - 32s 142ms/step - loss: 3.3330e-05 - accuracy: 1.0000 -
val_loss: 2.6152 - val_accuracy: 0.6938
```

```
Epoch 12/20
225/225 [==============================] - 32s 142ms/step - loss: 2.6515e-05 - accuracy: 1.0000 -
val_loss: 2.6719 - val_accuracy: 0.6931
Epoch 13/20
...
Epoch 19/20
225/225 [==============================] - 30s 132ms/step - loss: 7.2637e-06 - accuracy: 1.0000 -
val_loss: 3.0259 - val_accuracy: 0.6944
Epoch 20/20
225/225 [==============================] - 32s 141ms/step - loss: 6.1608e-06 - accuracy: 1.0000 -
val_loss: 3.0733 - val_accuracy: 0.6938
```

طبق مقاله مدل را در ۲۰ دور و با ۸۰۰ داده برای validation که برابر ۱۰ درصد می شود آموزش می دهیم.

```
# Plotting accuracy
plt.figure(figsize=(12, 4))

plt.subplot(1, 2, 1)
plt.plot(train_history.history['accuracy'], label='Training Accuracy')
plt.plot(train_history.history['val_accuracy'], label='Validation Accuracy')
plt.title('Training and Validation Accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()

# Plotting loss
plt.subplot(1, 2, 2)
plt.plot(train_history.history['loss'], label='Training Loss')
plt.plot(train_history.history['val_loss'], label='Validation Loss')
plt.title('Training and Validation Loss')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()

plt.tight_layout()
plt.show()
```

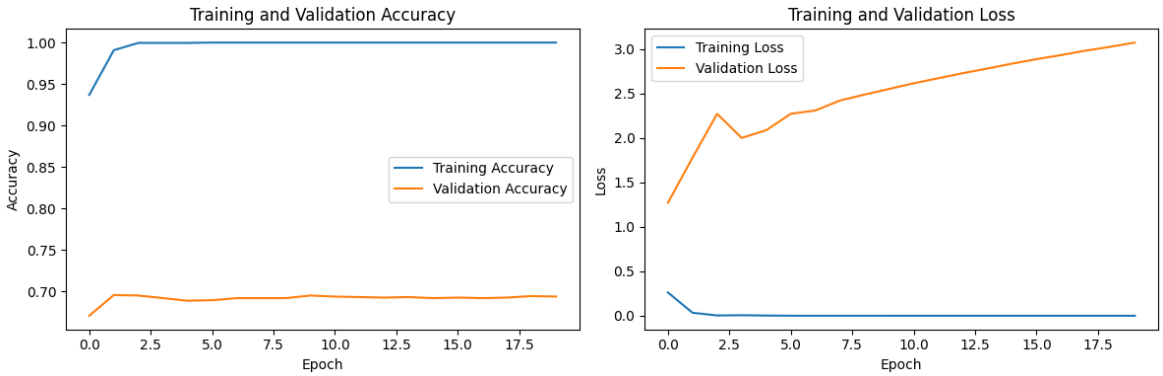

نمودار دقت و خطا

نمایش نمودار دقت و خطا هنگام آموزش مدل همان طور که مشخص است دقت مدل بر روی داده آموزشی برابر ۱۰۰ و برای داده ارزیابی برابر ۷۰ درصد است که نتایج قابل قبولی است.

۴-۲ ارزیابی و تحلیل نتایج

```
y_pred = model.predict(padded_test_sequences)
```

```
85/85 [==============================] - 4s 41ms/step
```

اجرای تابع پیشبینی برای تحلیل نتایج

```
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix
import numpy as np

conf_matrix_plt_labels = [f'Class {i}' for i in range(10)]

# Calculate the confusion matrix
conf_matrix = confusion_matrix(test_label, np.argmax(y_pred, axis=1))

# Plot the confusion matrix using seaborn heatmap
plt.figure(figsize=(8, 6))
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Blues',
            xticklabels=conf_matrix_plt_labels,
            yticklabels=conf_matrix_plt_labels,  # Replace with your class labels
            cbar_kws={'label': 'Count'})
plt.title('Confusion Matrix')
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.show()
```

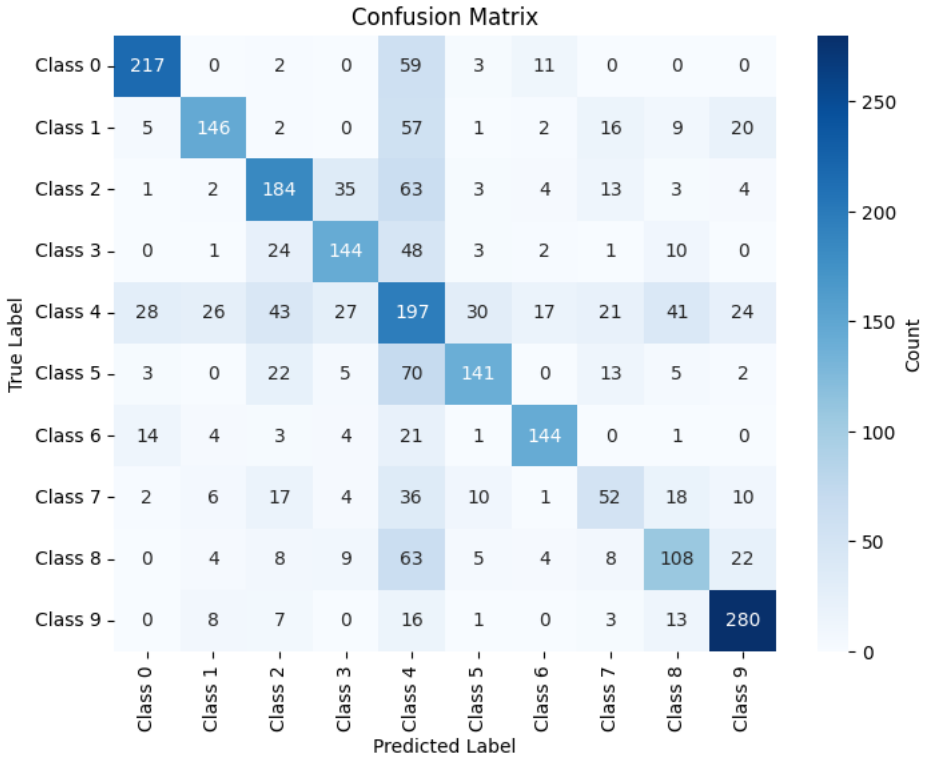

ماتریس درهم ریختگی

ماتریس درهم ریختگی را ترسیم می کنیم برای کلاس ۴ که (سایر) است نتایج کمی نامعتبر است ولی برای کلاس های دیگر عملکرد مدل قابل قبول است مخصوصا کلاس های ۰ و ۹

```
from sklearn.metrics import classification_report

classification_rep = classification_report(test_label,
np.argmax(y_pred, axis=1), target_names=conf_matrix_plt_labels)
print("Classification Report:")
print(classification_rep)
```

```
Classification Report:
              precision    recall  f1-score   support

     Class 0       0.80      0.74      0.77       292
     Class 1       0.74      0.57      0.64       258
     Class 2       0.59      0.59      0.59       312
     Class 3       0.63      0.62      0.62       233
     Class 4       0.31      0.43      0.36       454
     Class 5       0.71      0.54      0.61       261
     Class 6       0.78      0.75      0.76       192
     Class 7       0.41      0.33      0.37       156
     Class 8       0.52      0.47      0.49       231
     Class 9       0.77      0.85      0.81       328

    accuracy                           0.59      2717
   macro avg       0.63      0.59      0.60      2717
weighted avg       0.62      0.59      0.60      2717
```

در اینجا f1-score، precision،recall را برای هر کلاس محاسبه می کنیم که کلاس ۰ و ۶ بیشترین امتیاز f1 را دارند و کلاس ۴ و ۷ کمترین مقدار f1 که نشاندهنده عملکرد بد مدل در آنجا است.

پاسخ ۳ – تشخیص تقلب

۳-۱.

۳-۱-۱. کتابخانه

Question 3: A Convolutional Neural Network Model for Credit Card Fraud Detection

- The Aim of this notebook is finding fraud in transaction based on CNN models of paper:

https://ieeexplore.ieee.org/document/9862930

- It is important that credit card companies are able to recognize fraudulent credit card transactions so that customers are not charged for items that they did not purchase.
- The transactions are described by 30 features (V1, V2, . . ., V28, Time, and Amount) and then the class label which denotes a fraudulent transaction as "1" and a normal transaction as "0"

Dataset: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud/data

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import cv2
from sklearn.preprocessing import RobustScaler

import os
import seaborn as sns

import shutil
from google.colab import drive
from google.colab import files
```

۳-۱-۲. نمودار هیستوگرام کلاس‌ها

```
uploaded = files.upload()

!mkdir -p ~/.kaggle
!mv kaggle.json ~/.kaggle/
!chmod 600 ~/.kaggle/kaggle.json
!kaggle datasets download -d mlg-ulb/creditcardfraud
!unzip -q creditcardfraud.zip
```

```
df = pd.read_csv("./creditcard.csv")
df
```

```
df['Class'].value_counts()
```

```
0    284315
1       492
Name: Class, dtype: int64
```

خب در اینجا متوجه نابرابری توزیع کلاس ها می‌شویم

```
df.hist(bins=30,figsize=(30,30))
```

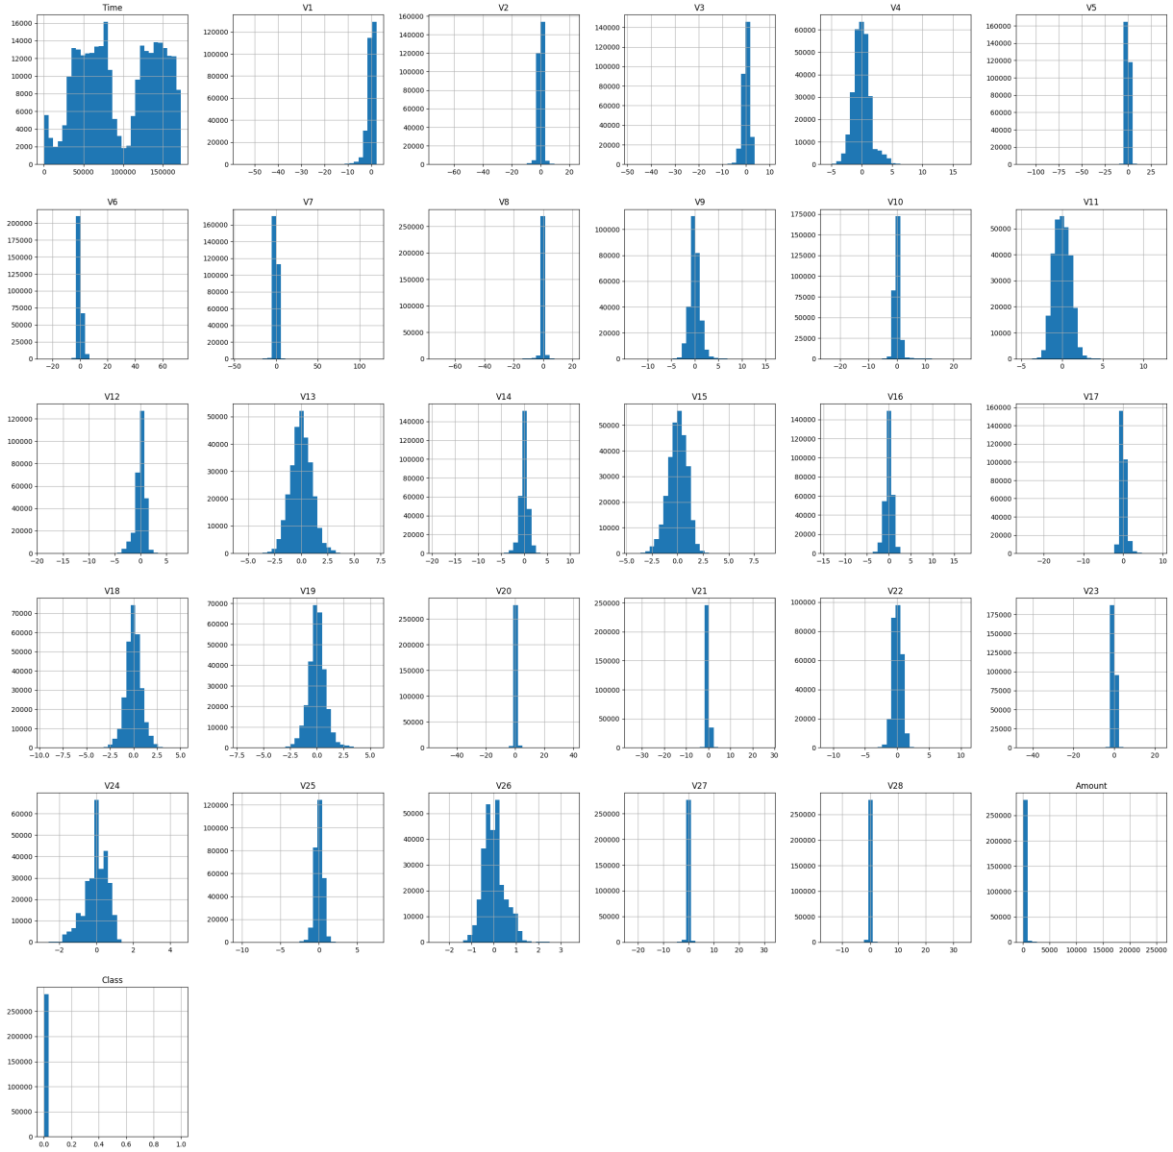

توزیع کلاس ها

```
df.describe()
```

۳-۱-۳. چرا نمی توانیم این کلاس ها را اموزش بدهیم؟

دیتاست داده شده از تراکنش های حاصله دو روز کاری 492 تا entry fraud و 284.807 تا تراکنش عادی دارد.
خب این دیتاست بسیار unbalanced هست برای کلاس fraud و 0.172% کل تراکنش را شامل می‌شود.
براي همين هنگام اموزش خيلي روي كلاس negative fragility دارد.
چون 99% تراکنش ها شيادي حساب نمي‌شود الگوريتم ها با احتمال زياد تري هميشه non-fraud براورد مي‌كنند.
با این حالت با درصد بالايي دقت 99% بدست مي‌آيد در داده train. ما دنبال این کار نیستیم و دنبال generalize بودن هستیم بنابر این نیاز داریم که new labeling داشته باشیم که توزیع درست براورد کنیم.

۳-۲. پیاده سازی مدل مقاله

۳-۲-۱. پیش پردازش

```
new_df = df.copy()
time = new_df['Time']
```

```
new_df['Amount'] = RobustScaler().fit_transform(new_df['Amount'].to_numpy().reshape(-1,1))
new_df['Time'] = (time - time.min()) / (time.max() - time.min())
```

۲-۲-۳. آموزش با داده های unbalanced

```
from sklearn.model_selection import train_test_split
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv1D, BatchNormalization, MaxPool1D, Dropout, Flatten, Dense
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.losses import BinaryCrossentropy
from tensorflow.keras.metrics import Accuracy
```

```
X = df.drop('Class', axis=1)
y = df['Class']

X_unbalanced = X.values
y_unbalanced = y.values
```

```
X_unbalanced_reshaped = X_unbalanced.reshape(X_unbalanced.shape[0], X_unbalanced.shape[1], 1)
```

```
X_train, X_temp, y_train, y_temp = train_test_split(X_unbalanced_reshaped, y_unbalanced, test_size=0.4, random_state=42)
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size=0.5, random_state=42)

print("Training set shape:", X_train.shape)
print("Validation set shape:", X_val.shape)
print("Testing set shape:", X_test.shape)
```

```
Training set shape: (170884, 30, 1)
Validation set shape: (56961, 30, 1)
Testing set shape: (56962, 30, 1)
```

```
model = Sequential()

model.add(Conv1D(filters=32, kernel_size=2, activation='relu', input_shape=(X_train.shape[1], 1)))

model.add(BatchNormalization())

model.add(MaxPool1D(pool_size=2))

model.add(Dropout(rate=0.2))

model.add(Conv1D(filters=64, kernel_size=2, activation='relu'))

model.add(BatchNormalization())

model.add(MaxPool1D(pool_size=2))

model.add(Dropout(rate=0.5))

model.add(Flatten())

model.add(Dense(units=64, activation='relu'))
```

```
model.add(Dropout(rate=0.5))

model.add(Dense(units=64, activation='relu'))

model.add(Dense(units=1, activation='sigmoid'))


model.compile(optimizer=Adam(learning_rate=0.0001),
              loss=BinaryCrossentropy(),
              metrics=[Accuracy()])


model.summary()
```

```
Model: "sequential_4"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv1d_7 (Conv1D)           (None, 29, 32)            96

 batch_normalization_6 (Bat  (None, 29, 32)            128
 chNormalization)

 max_pooling1d_6 (MaxPoolin  (None, 14, 32)            0
 g1D)

 dropout_9 (Dropout)         (None, 14, 32)            0

 conv1d_8 (Conv1D)           (None, 13, 64)            4160

 batch_normalization_7 (Bat  (None, 13, 64)            256
 chNormalization)

 max_pooling1d_7 (MaxPoolin  (None, 6, 64)             0
 g1D)

 dropout_10 (Dropout)        (None, 6, 64)             0

 flatten_3 (Flatten)         (None, 384)               0
...
Total params: 33505 (130.88 KB)
Trainable params: 33313 (130.13 KB)
Non-trainable params: 192 (768.00 Byte)
_________________________________________________________________
```

```
history = model.fit(X_train, y_train, epochs=6, batch_size=32, validation_data=(X_val,
y_val))
```

```
Epoch 1/6
5341/5341 [==============================] - 45s 8ms/step - loss: 0.0183 - accuracy:
0.0000e+00 - val_loss: 0.0064 - val_accuracy: 0.0000e+00
Epoch 2/6
5341/5341 [==============================] - 38s 7ms/step - loss: 0.0078 - accuracy:
0.0000e+00 - val_loss: 0.0058 - val_accuracy: 1.7556e-05
Epoch 3/6
5341/5341 [==============================] - 38s 7ms/step - loss: 0.0066 - accuracy:
5.8519e-06 - val_loss: 0.0048 - val_accuracy: 0.0000e+00
Epoch 4/6
5341/5341 [==============================] - 38s 7ms/step - loss: 0.0059 - accuracy:
0.0000e+00 - val_loss: 0.0044 - val_accuracy: 0.0000e+00
Epoch 5/6
```

```
5341/5341 [==============================] - 38s 7ms/step - loss: 0.0052 - accuracy:
0.0000e+00 - val_loss: 0.0039 - val_accuracy: 0.0000e+00
Epoch 6/6
5341/5341 [==============================] - 38s 7ms/step - loss: 0.0053 - accuracy:
0.0000e+00 - val_loss: 0.0043 - val_accuracy: 0.0000e+00
```

```python
plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
plt.plot(history.history['loss'], label='Training Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.title('Training and Validation Loss')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()

plt.subplot(1, 2, 2)
plt.plot(history.history['accuracy'], label='Training Accuracy')
plt.plot(history.history['val_accuracy'], label='Validation Accuracy')
plt.title('Training and Validation Accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()

plt.tight_layout()
plt.show()
```

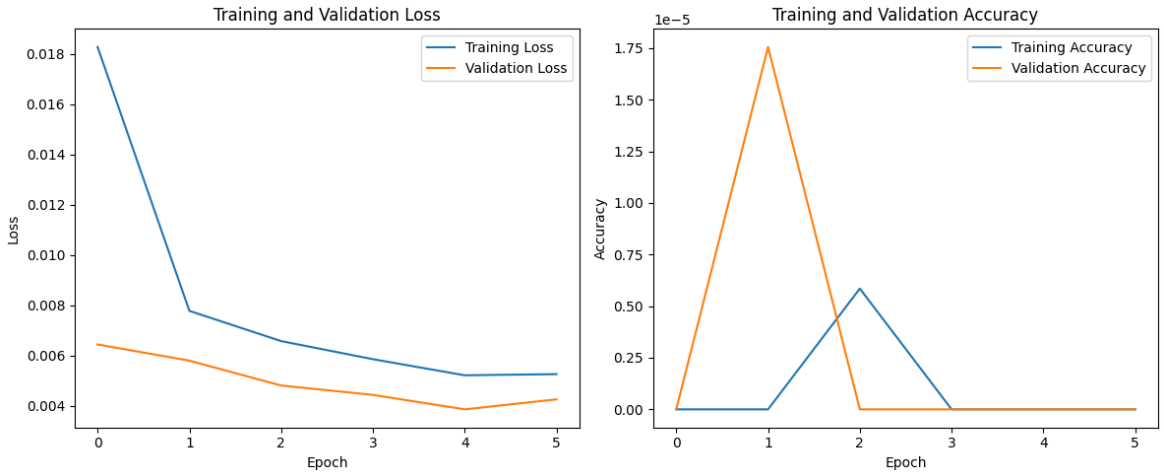

نمودار دقت و خطا

```python
from sklearn.metrics import confusion_matrix, classification_report
import seaborn as sns
import matplotlib.pyplot as plt

# Obtain model predictions for the test data
y_pred = model.predict(X_test)
y_pred_binary = (y_pred > 0.5).astype(int)  # Convert to binary predictions (0 or 1)

# Calculate and plot the confusion matrix heatmap
cm = confusion_matrix(y_test, y_pred_binary)
plt.figure(figsize=(8, 6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', cbar=False,
            xticklabels=['Legitimate', 'Fraud'],
            yticklabels=['Legitimate', 'Fraud'])
plt.title('Confusion Matrix')
```

```
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.show()

# Report precision, recall, and F1 score
report = classification_report(y_test, y_pred_binary, target_names=['Legitimate',
'Fraud'])
print("Classification Report:")
print(report)
```

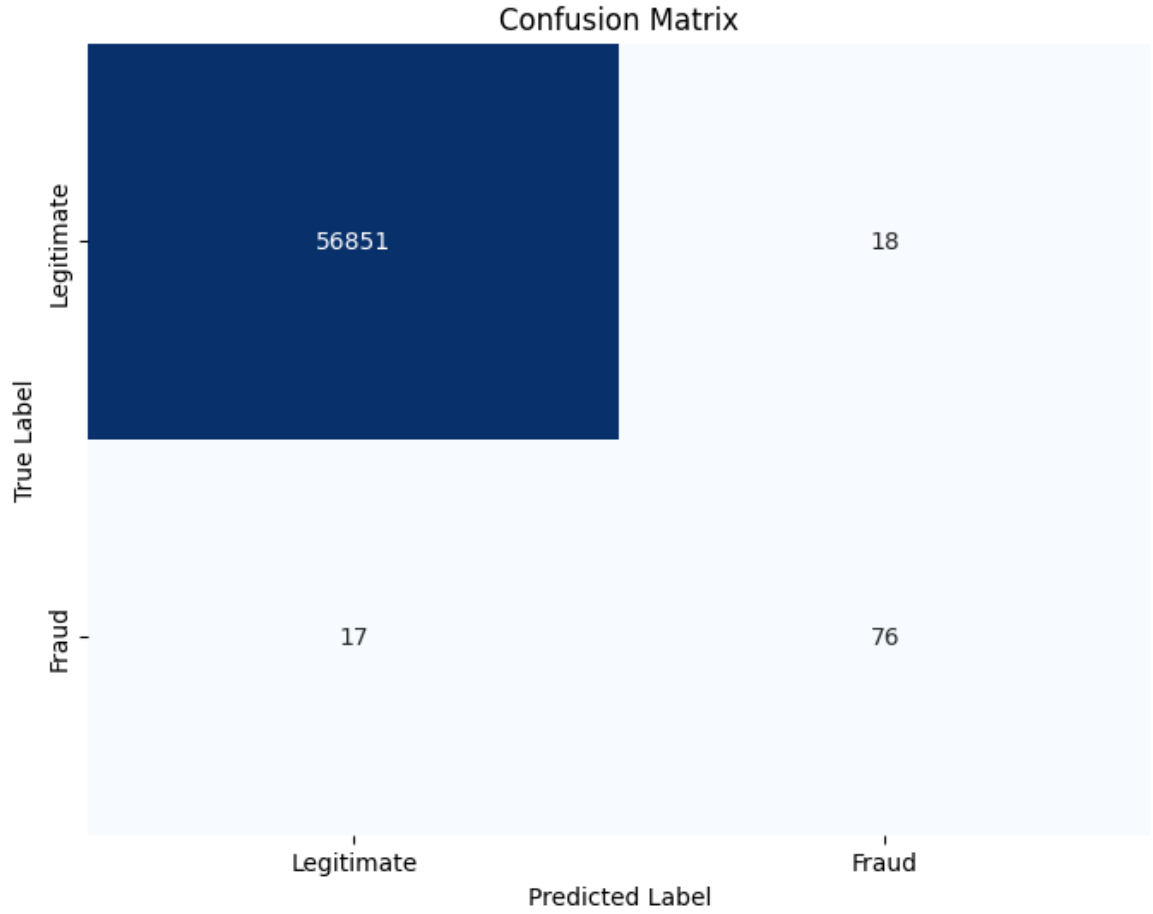

ماتریس درهم ریختگی

```
Classification Report:
              precision    recall  f1-score   support

  Legitimate       1.00      1.00      1.00     56869
       Fraud       0.81      0.82      0.81        93

    accuracy                           1.00     56962
   macro avg       0.90      0.91      0.91     56962
weighted avg       1.00      1.00      1.00     56962
```

خب همانطور که اشاره کردیم احتمال می‌رفت که گزارش نتایج بالا قابل اتکا کردن نباشد.

۳-۳. نمونه برداری – به کمک Adaptive Synthetic Sampling (ADASYN)

ADASYN

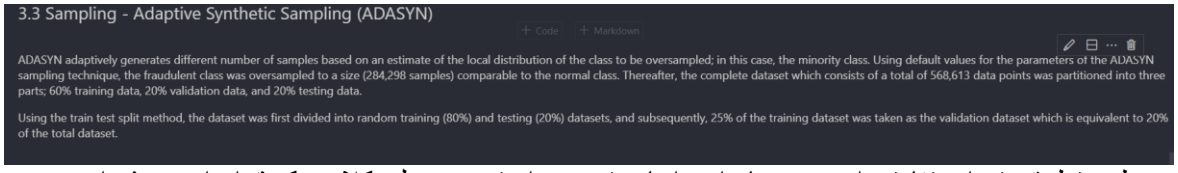

به طور تطبیقی تعداد متفاوتی از نمونه ها را بر اساس تخمینی از توزیع محلی کلاسی که قرار است بیش از حد نمونه برداری شود تولید می کند. در این مورد، طبقه اقلیت. با استفاده از مقادیر پیش‌فرض برای پارامترهای تکنیک نمونه‌گیری ADASYN، کلاس تقلبی به اندازه (284298 نمونه) بیش از حد نمونه‌گیری شد که با کلاس معمولی قابل مقایسه بود. پس از آن، مجموعه داده کامل که از مجموع 568613 نقطه داده تشکیل شده است به سه بخش تقسیم شد. 60 درصد داده های آموزشی، 20 درصد داده های اعتبار سنجی و 20 درصد داده های آزمایشی.

با استفاده از روش train test split دادگان به صورت رندم به 80 20 براي train و test و 25 درصد داده هاي باقي مانده training که متعاقبا معادل 20 درصد کل دیتاست است برايvalidation در نظر گرفته شد.

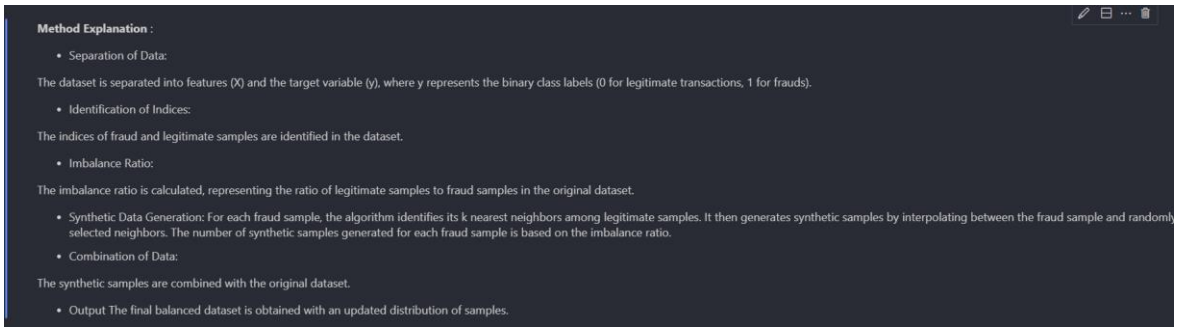

توزیح متد:

- جداسازی دیتا

در این بخش feature (x) و target (y) جداسازی می‌شودکه y یک باینری دوتایی 0 1 هست.

- مشخص سازی indices

The indices از fraud و legitimate مشخص می‌شود.

- مشخص کردنImbalance ratio

Ratio ناوزنی بین دادگان مشخص و حساب می‌شود.

- ساخت دیتای مصنوعی

1- برای هر نمونه تقلب، الگوریتم k نزدیکترین همسایه خود را در بین نمونه های قانونی شناسایی می کند.

2- سپس با درون یابی بین نمونه تقلب و همسایگان به طور تصادفی انتخاب شده، نمونه های مصنوعی تولید می کند.

تعداد نمونه های مصنوعی تولید شده برای هر نمونه تقلب بر اساس نسبت عدم تعادل است.

- ترکیب دیتا

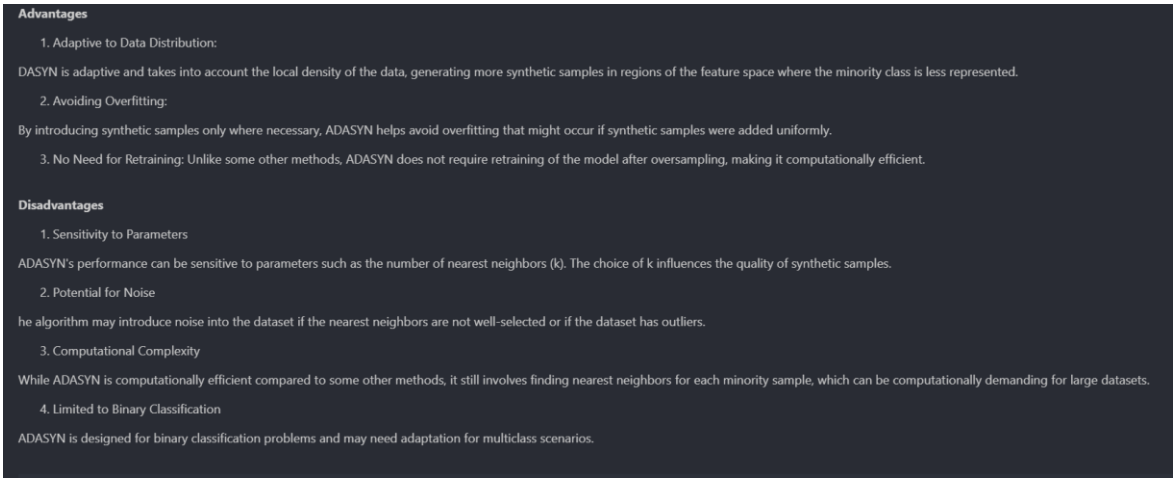

مزایا و معایب:
مزایا:
1. سازگار با توزیع داده:

DASYN تطبیقی است و چگالی محلی داده ها را در نظر می گیرد و نمونه های مصنوعی بیشتری را در مناطقی از فضای ویژگی ایجاد می کند که در آن کلاس اقلیت کمتر نمایش داده می شود.

2. اجتناب از Overfit:

ADASYN با معرفی نمونه‌های مصنوعی فقط در صورت لزوم، به جلوگیری از برازش بیش از حد که ممکن است در صورت اضافه شدن یکنواخت نمونه‌های مصنوعی رخ دهد، کمک می‌کند.

3. عدم نیاز به آموزش مجدد:
برخلاف برخی روش‌های دیگر، ADASYN نیازی به آموزش مجدد مدل پس از نمونه‌برداری بیش‌ازحد ندارد و آن را از نظر محاسباتی کارآمد می‌کند.

معایب:

1. حساسیت به پارامترها

عملکرد ADASYN می تواند به پارامترهایی مانند تعداد نزدیکترین همسایگان (k) حساس باشد. انتخاب k بر کیفیت نمونه های مصنوعی تأثیر می گذارد.

2. پتانسیل برای نویز

اگر نزدیکترین همسایگان به خوبی انتخاب نشده باشند یا اگر مجموعه داده دارای مقادیر پرت باشد، الگوریتم ممکن است نویز را به مجموعه داده وارد کند.

3. پیچیدگی محاسباتی

در حالی که ADASYN از نظر محاسباتی در مقایسه با برخی روش‌های دیگر کارآمد است، اما همچنان شامل یافتن نزدیک‌ترین همسایگان برای هر نمونه اقلیت است، که می‌تواند از نظر محاسباتی برای مجموعه‌های داده بزرگ نیاز باشد.

4. محدود به طبقه بندی باینری

ADASYN برای مسائل طبقه بندی باینری طراحی شده است و ممکن است برای سناریوهای چند کلاسه نیاز به تطبیق داشته باشد.

```
# Separate the dataset into features (X) and the target variable (y)
X = df.drop('Class', axis=1)
y = df['Class']

# Identify the indices of fraud and legitimate samples
fraud_indices = np.where(y == 1)[0]
legitimate_indices = np.where(y == 0)[0]

# Calculate the imbalance ratio
imbalance_ratio = len(legitimate_indices) / len(fraud_indices)

# Initialize variables for the synthetic data
synthetic_features = []
synthetic_labels = []

# Loop over each fraud sample and generate synthetic samples
for fraud_index in fraud_indices:
    # Find the k nearest neighbors of the fraud sample
    k_neighbors = np.argsort(np.linalg.norm(X.values[legitimate_indices] -
X.values[fraud_index], axis=1))[:5]

    # Calculate the number of synthetic samples to generate for the current fraud sample
    num_synthetic_samples = int(imbalance_ratio) - 1

    #  Generate synthetic samples
    for _ in range(num_synthetic_samples):
        random_neighbor_index = np.random.choice(k_neighbors)
        synthetic_sample = X.values[fraud_index] + np.random.rand() *
(X.values[random_neighbor_index] - X.values[fraud_index])
        synthetic_features.append(synthetic_sample)
        synthetic_labels.append(1)  # Label for fraud sample
```

```
#  Combine the synthetic samples with the original dataset
X_balanced = np.vstack((X.values, np.array(synthetic_features)))
y_balanced = np.concatenate((y.values, np.array(synthetic_labels)))
```

```
# Print the dataset distribution before and after balancing
print("TABLE I. DATASET DISTRIBUTION")
print("Dataset \t Legitimate \t Fraud \t\t Total")
print("Before Balancing \t {} \t\t {} \t\t {}".format(len(legitimate_indices),
len(fraud_indices), len(y)))
print("After Balancing \t {} \t\t {} \t\t {}".format(len(np.where(y_balanced == 0)[0]),
len(np.where(y_balanced == 1)[0]), len(y_balanced)))
```

```
TABLE I. DATASET DISTRIBUTION
Dataset         Legitimate      Fraud           Total
Before Balancing        284315                  492             284807
After Balancing         284315                  283884                  568199
```

همان طور که بالا محاسبه کردیم توزیع داده ها برابر شده است.

۳-۳-۳. توزیح دهید نمونه برداری باید قبل از تقسیم داده ها به اموزش و تست انجام بشود یا بعد از ان؟

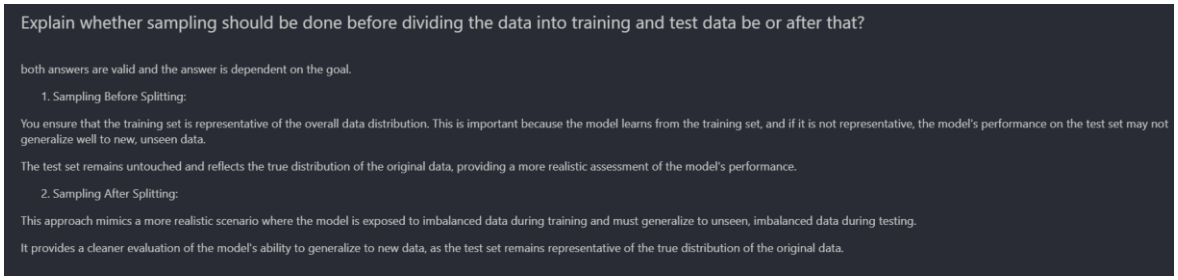

هر دو پاسخ معتبر است و پاسخ به هدف بستگی دارد.

1. نمونه برداری قبل از تقسیم:

شما مطمئن می شوید که مجموعه آموزشی نماینده توزیع کلی داده است. این مهم است زیرا مدل از مجموعه آموزش یاد می گیرد و اگر نماینده نباشد ، عملکرد مدل در مجموعه آزمون ممکن است به خوبی به داده های جدید و غیب تعمیم ندهد.

مجموعه آزمون دست نخورده باقی مانده و توزیع واقعی داده های اصلی را منعکس می کند و ارزیابی واقعی تری از عملکرد مدل ارائه می دهد.

2. نمونه برداری پس از تقسیم:

این رویکرد سناریوی واقع بینانه تری را تقلید می کند که در آن مدل در طول آموزش در معرض داده های نامتعادل قرار می گیرد و باید در طول آزمایش به داده های ناشناخته و نابرابر تعمیم یابد.

این یک ارزیابی تمیزتر از توانایی مدل برای تعمیم داده های جدید را ارائه می دهد ، زیرا مجموعه آزمون نماینده توزیع واقعی داده های اصلی است.

```
df_balanced = pd.DataFrame(data=np.column_stack((X_balanced, y_balanced)),
columns=df.columns)

df_balanced
```

```
df_balanced.hist(bins=30,figsize=(30,30))
```

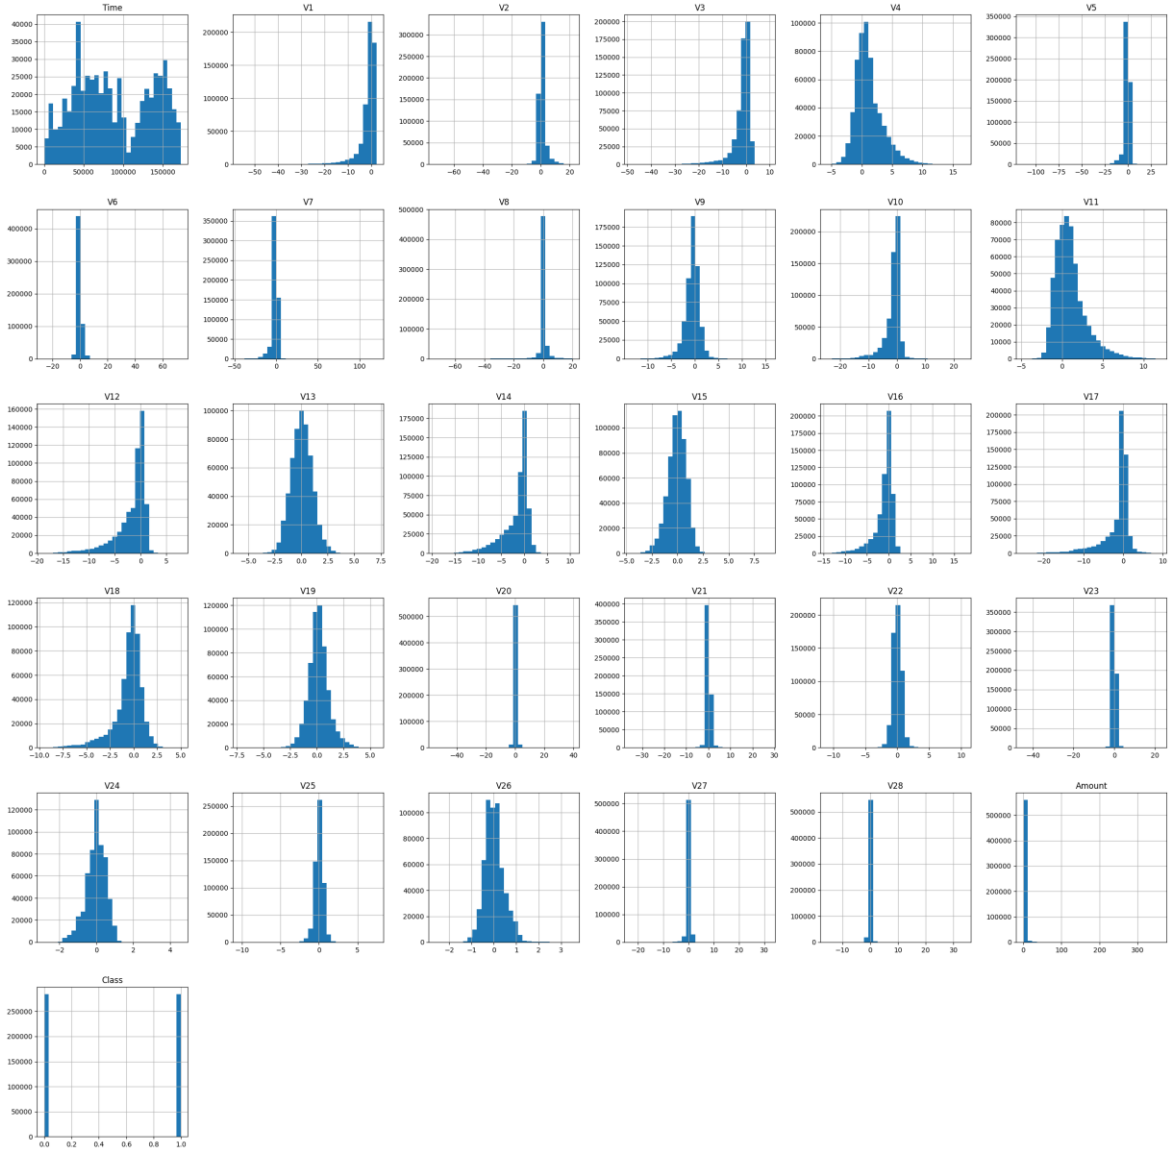

نمودارتوزیع کلاس ها

در اینجا اخرین کلاس میبینیم که برچسب target توازن دارند.

نمونه برداري و تقسيم بندي:

```
from sklearn.model_selection import train_test_split

X_balanced_reshaped = X_balanced.reshape(X_balanced.shape[0], X_balanced.shape[1], 1)
```

```
X_train, X_temp, y_train, y_temp = train_test_split(X_balanced_reshaped, y_balanced,
test_size=0.4, random_state=42)
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size=0.5,
random_state=42)
```

```
print("Training set shape:", X_train.shape)
print("Validation set shape:", X_val.shape)
print("Testing set shape:", X_test.shape)
```

```
Training set shape: (340919, 30, 1)
Validation set shape: (113640, 30, 1)
```

```
Testing set shape: (113640, 30, 1)
```

۴-۳. آموزش مدل

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv1D, BatchNormalization, MaxPool1D, Dropout,
Flatten, Dense
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.losses import BinaryCrossentropy
from tensorflow.keras.metrics import Accuracy
```

```
model = Sequential()

model.add(Conv1D(filters=32, kernel_size=2, activation='relu',
input_shape=(X_train.shape[1], 1)))

model.add(BatchNormalization())

model.add(MaxPool1D(pool_size=2))

model.add(Dropout(rate=0.2))

model.add(Conv1D(filters=64, kernel_size=2, activation='relu'))

model.add(BatchNormalization())

model.add(MaxPool1D(pool_size=2))

model.add(Dropout(rate=0.5))

model.add(Flatten())

model.add(Dense(units=64, activation='relu'))

model.add(Dropout(rate=0.5))

model.add(Dense(units=64, activation='relu'))

model.add(Dense(units=1, activation='sigmoid'))


model.compile(optimizer=Adam(learning_rate=0.0001),
              loss=BinaryCrossentropy(),
              metrics=[Accuracy()])


model.summary()
```

```
Model: "sequential_3"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv1d_5 (Conv1D)           (None, 29, 32)            96
```

```
 batch_normalization_4 (Bat  (None, 29, 32)            128
 chNormalization)

 max_pooling1d_4 (MaxPoolin  (None, 14, 32)            0
 g1D)

 dropout_6 (Dropout)         (None, 14, 32)            0

 conv1d_6 (Conv1D)           (None, 13, 64)            4160

 batch_normalization_5 (Bat  (None, 13, 64)            256
 chNormalization)

 max_pooling1d_5 (MaxPoolin  (None, 6, 64)             0
 g1D)

 dropout_7 (Dropout)         (None, 6, 64)             0

 flatten_2 (Flatten)         (None, 384)               0
...
Total params: 33505 (130.88 KB)
Trainable params: 33313 (130.13 KB)
Non-trainable params: 192 (768.00 Byte)
```

```
history = model.fit(X_train, y_train, epochs=6, batch_size=32, validation_data=(X_val,
y_val))
```

```
Epoch 1/6
10654/10654 [==============================] - 81s 8ms/step - loss: 0.3358 - accuracy:
0.0755 - val_loss: 0.2760 - val_accuracy: 0.1125
Epoch 2/6
10654/10654 [==============================] - 80s 7ms/step - loss: 0.2994 - accuracy:
0.1120 - val_loss: 0.2601 - val_accuracy: 0.1262
Epoch 3/6
10654/10654 [==============================] - 78s 7ms/step - loss: 0.2838 - accuracy:
0.1293 - val_loss: 0.2501 - val_accuracy: 0.1406
Epoch 4/6
10654/10654 [==============================] - 79s 7ms/step - loss: 0.2754 - accuracy:
0.1300 - val_loss: 0.2392 - val_accuracy: 0.1291
Epoch 5/6
10654/10654 [==============================] - 76s 7ms/step - loss: 0.2655 - accuracy:
0.1377 - val_loss: 0.2376 - val_accuracy: 0.1198
Epoch 6/6
10654/10654 [==============================] - 80s 7ms/step - loss: 0.2613 - accuracy:
0.1306 - val_loss: 0.2397 - val_accuracy: 0.0905
```

```
plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
plt.plot(history.history['loss'], label='Training Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.title('Training and Validation Loss')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()

plt.subplot(1, 2, 2)
plt.plot(history.history['accuracy'], label='Training Accuracy')
plt.plot(history.history['val_accuracy'], label='Validation Accuracy')
plt.title('Training and Validation Accuracy')
```

```
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()

plt.tight_layout()
plt.show()
```

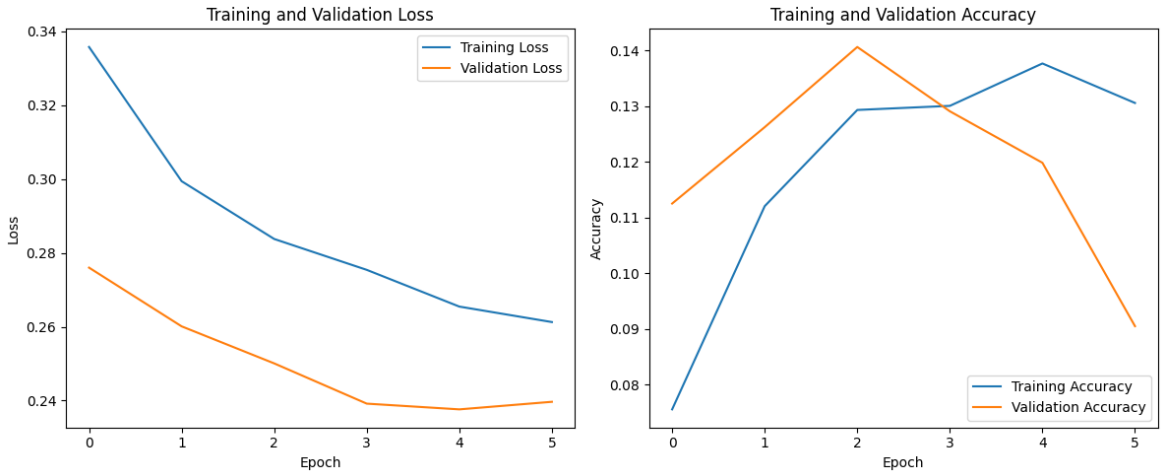

نمودار دقت و خطا

```
from sklearn.metrics import confusion_matrix, classification_report
import seaborn as sns
import matplotlib.pyplot as plt

# Obtain model predictions for the test data
y_pred = model.predict(X_test)
y_pred_binary = (y_pred > 0.5).astype(int)  # Convert to binary predictions (0 or 1)

# Calculate and plot the confusion matrix heatmap
cm = confusion_matrix(y_test, y_pred_binary)
plt.figure(figsize=(8, 6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', cbar=False,
            xticklabels=['Legitimate', 'Fraud'],
            yticklabels=['Legitimate', 'Fraud'])
plt.title('Confusion Matrix')
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.show()

# Report precision, recall, and F1 score
report = classification_report(y_test, y_pred_binary, target_names=['Legitimate',
'Fraud'])
print("Classification Report:")
print(report)
```

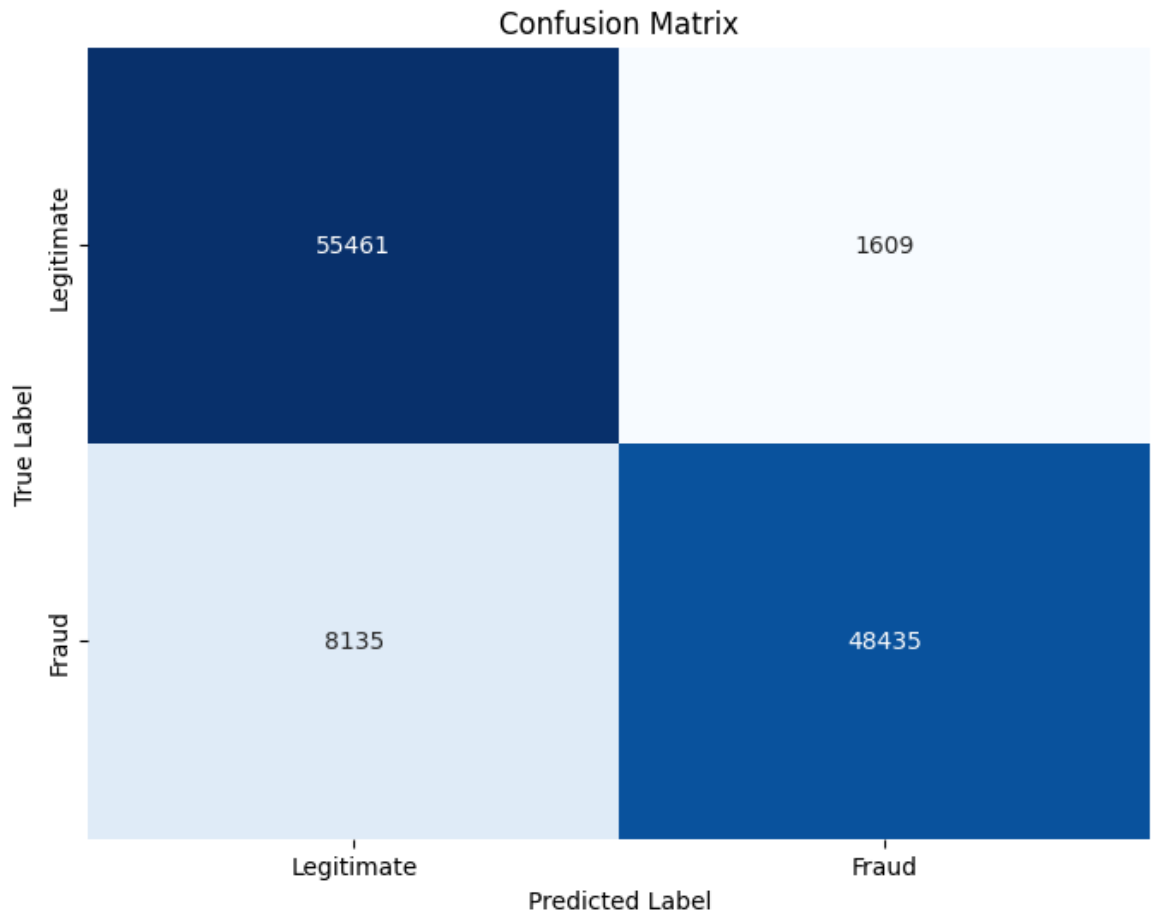

ماتریس درهم ریختگی

```
Classification Report:
              precision    recall  f1-score   support

  Legitimate       0.87      0.97      0.92     57070
       Fraud       0.97      0.86      0.91     56570

    accuracy                           0.91    113640
   macro avg       0.92      0.91      0.91    113640
weighted avg       0.92      0.91      0.91    113640
```

در این حالت نتایج دریافت شده قابل اتکا بوده و به دقت 91 درصد می‌رسیم.